Projeto 2: Quantização de Cores com SOM e GNG

Disciplina: Introdução às Redes Neurais Artificiais

Autor(es): Enzo Rosim (RA: 187389)

Repositório / Código Reprodutível:
https://github.com/EnzoRosim/Projeto_NaoSupervisionado

---

1. Configuração Experimental e Reprodutibilidade

1.1. Base de Dados e Pré-processamento

Foram utilizadas 5 imagens coloridas (`image1` a `image5`), apresentadas na Figura 1. Todas têm 100×100 pixels (10.000 amostras cada, respeitando o limite de 128 px de lado) e possuem, respectivamente, 8908, 8187, 7952, 7534 e 6270 cores distintas. Cada imagem foi carregada e todos os seus pixels foram extraídos, de modo que cada pixel constitui uma amostra com três características (canais R, G e B). Os valores foram normalizados para o intervalo $[0, 1]$ dividindo-se por 255 (por exemplo, o pixel $(255, 128, 0)$ torna-se (1,00; 0,50; 0,00)). Não há partição treino/teste: o treinamento é não supervisionado e a avaliação é feita sobre todos os pixels da própria imagem. Todas as redes usam semente aleatória fixa (`semente=42`) e o treinamento segue por um número fixo de iterações, proporcional ao número de neurônios (500 iterações por neurônio).

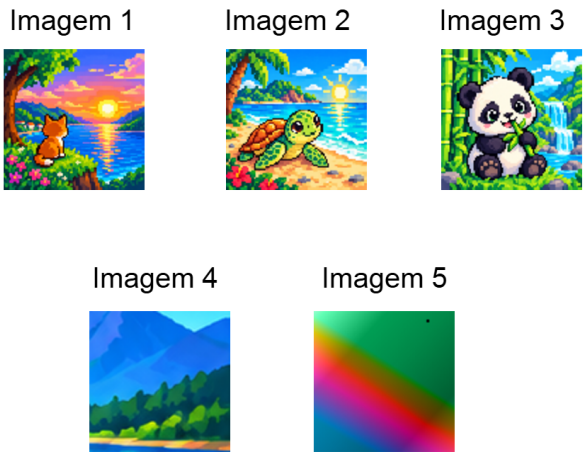


Figure 1: Base de imagens utilizada (`image1` a `image5`).

1.2. Modelos e Hiperparâmetros

Foram treinadas 30 redes: para cada uma das 5 imagens, 3 arquiteturas SOM (grids 4×4, 8×8 e 16×16) e 3 arquiteturas GNG (16, 64 e 256 neurônios), de modo que cada par SOM/GNG tem o mesmo número de neurônios. Em ambas as redes, cada neurônio guarda um vetor de pesos em $\mathbb{R}^3$, interpretado como uma cor. A Tabela 1 detalha as configurações.

Table 1: Arquiteturas e hiperparâmetros das redes SOM e GNG.

Item	**SOM**	**GNG**
Arquiteturas	Grids 4×4, 8×8 e 16×16 (16, 64 e 256 neurônios)	16, 64 e 256 neurônios (crescimento até o tamanho-alvo)
Topologia	Grid retangular fixo	Grafo dinâmico (arestas criadas e removidas)
Taxas de aprendizado	η: 0,5 $\rightarrow$ 0,01	$\epsilon_b = 0{,}2$ (vencedor); $\epsilon_n = 0{,}006$ (vizinhos)
Vizinhança / conexões	Raio: 2,0 $\rightarrow$ 0,5 (4×4); 4,0 $\rightarrow$ 0,5 (8×8); 8,0 $\rightarrow$ 0,5 (16×16)	Idade máxima das arestas $a_{max} = 50$
Crescimento	—	Inserção a cada $\lambda = 100$ iterações; $\alpha = 0{,}5$; $\beta = 0{,}0005$
Critério de parada	8.000, 32.000 e 128.000 iterações (16, 64 e 256 neurônios)	8.000, 32.000 e 128.000 iterações (16, 64 e 256 neurônios)
Semente aleatória	42	42

1.3. Inferência, Reconstrução e Métricas

Após o treinamento, cada pixel original $\mathbf{x}_k$ é associado ao neurônio vencedor (BMU), isto é, o de menor distância euclidiana, e sua cor é substituída pelos pesos desse neurônio. A imagem é então reconstruída com as novas cores (uma rede de 16 neurônios gera no máximo 16 cores distintas). As redes foram avaliadas por duas métricas:

- **Erro de quantização (EQ):** distância média entre cada pixel e a sua BMU, $EQ = \frac{1}{N}\sum_{k=1}^{N}\|\mathbf{x}_k - \mathbf{w}_{BMU(\mathbf{x}_k)}\|$. Quanto menor, mais fiel é a imagem reconstruída.
- **Erro topológico (ET):** fração de pixels cuja primeira e segunda BMU **não** são vizinhas (vizinhas no grid, para o SOM; ligadas por uma aresta, para a GNG). Quanto menor, melhor a preservação da topologia.

2. Evolução do Treinamento (Imagem 1): SOM vs. GNG

A evolução do treinamento sobre a imagem 1 foi acompanhada visualmente para o SOM (Figura 2) e para a GNG (Figura 3), permitindo comparar como cada modelo passa de cores aleatórias a uma paleta representativa.

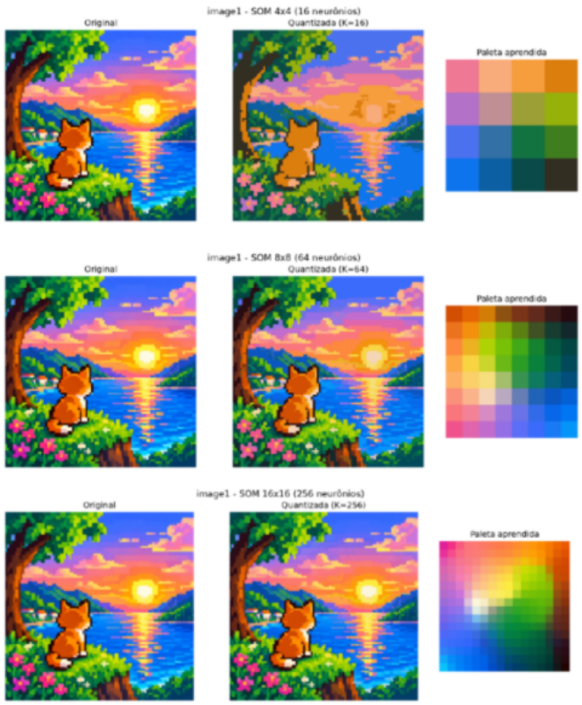


Figure 2: Evolução do SOM na imagem 1 (grids 4×4, 8×8 e 16×16).

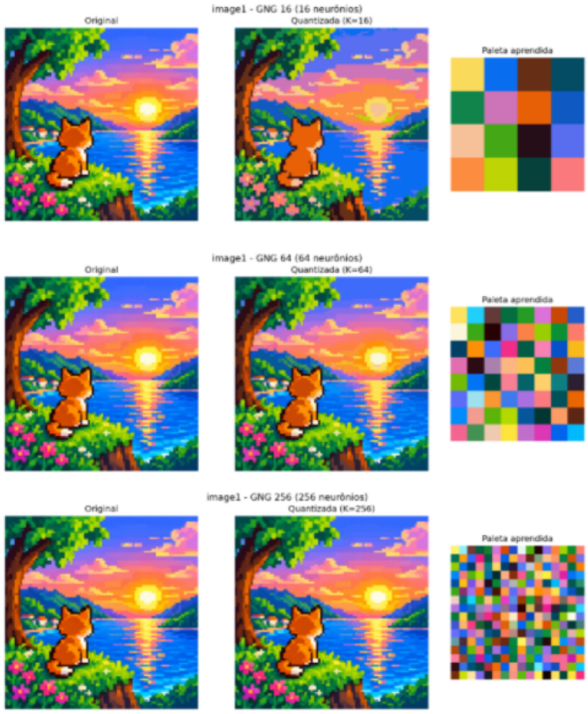


Figure 3: Evolução da GNG na imagem 1 (16, 64 e 256 neurônios).

Análise Crítica da Evolução:

- **Aprendizado competitivo no SOM:** na imagem 1, o EQ do SOM cai de 0,1479 (4×4) para 0,0666 (8×8) e 0,0308 (16×16): quanto maior o grid, mais a imagem reconstruída se aproxima da original. A cada iteração, a BMU e seus vizinhos no grid são puxados em direção ao pixel apresentado; por isso, cores parecidas acabam em posições próximas do grid. O raio de vizinhança diminui até 0,5, o que reduz a influência sobre os vizinhos e deixa a etapa final como um ajuste fino da própria BMU.
- **Crescimento da GNG:** a rede começa pequena e ganha um neurônio a cada $\lambda = 100$ iterações, sempre na região de maior erro acumulado. Supondo o início com 2 neurônios (como no algoritmo original), a rede de 256 neurônios atinge o tamanho final após cerca de 25.400 das 128.000 iterações, ou seja, aproximadamente 20% do treinamento; o restante é refinamento das posições. O EQ na imagem 1 cai de 0,1162 (16 neurônios) para 0,0487 (64) e 0,0238 (256).
- **Comparação visual:** com o mesmo número de neurônios, a GNG obteve EQ menor que o SOM na imagem 1 nos três tamanhos (0,1162 vs. 0,1479; 0,0487 vs. 0,0666; 0,0238 vs. 0,0308), cerca de 21%, 27% e 23% menor. Com 16 neurônios, as 8908 cores originais são reduzidas a no máximo 16, e tendem a surgir faixas de cor (*banding*) nas regiões de gradiente suave; com 256 neurônios, o erro médio é pequeno e a diferença para o original tende a ser pouco perceptível.

3. Desempenho Quantitativo (Imagem 5)

Os erros de quantização e topológico de todas as arquiteturas foram calculados sobre a imagem 5 e estão resumidos na Tabela 2 e na Figura 4. Para uma visão geral, a Tabela 3 traz a média das 5 imagens e o tempo médio de treinamento.

Table 2: Erros de quantização e topológico na imagem 5.

Rede	Arquitetura	Erro de Quantização (EQ)	Erro Topológico (ET)
SOM	4×4 (16 neurônios)	0.1060	0.0015
SOM	8×8 (64 neurônios)	0.0488	0.0019
SOM	16×16 (256 neurônios)	0.0224	0.0193
GNG	16 neurônios	0.0845	0.0029
GNG	64 neurônios	0.0413	0.0073
GNG	256 neurônios	**0.0194**	0.0078

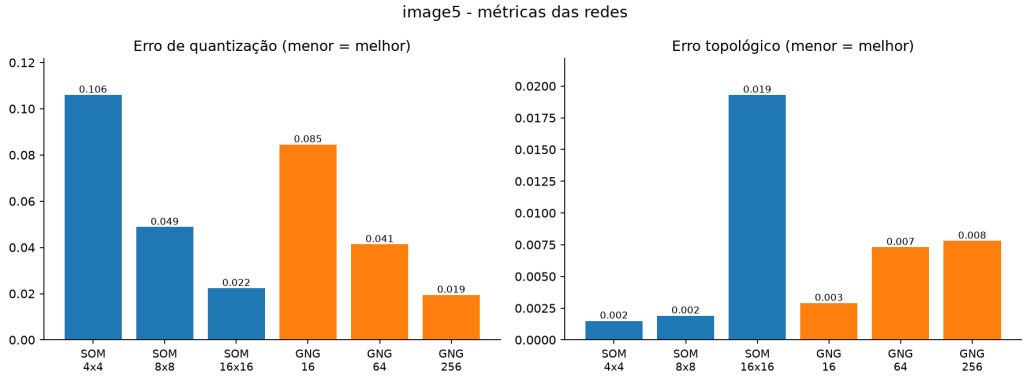


Figure 4: Erro topológico e erro de quantização das redes SOM e GNG na imagem 5.

Table 3: Média por rede sobre as 5 imagens.

Rede	Neurônios	EQ médio	ET médio	Tempo médio
SOM 4×4	16	0.1153	0.0025	0,1 s
SOM 8×8	64	0.0516	0.0077	0,6 s
SOM 16×16	256	0.0249	0.0242	3,8 s
GNG 16	16	0.0912	0.0031	0,2 s
GNG 64	64	0.0405	0.0073	1,1 s
GNG 256	256	**0.0205**	0.0084	4,7 s

4. Discussão e Lições Aprendidas

- **Efeito do Tamanho da Rede:** a cada vez que o número de neurônios é multiplicado por 4 ($16 \to 64 \to 256$), o EQ médio cai aproximadamente pela metade: SOM de 0,1153 para 0,0516 e 0,0249; GNG de 0,0912 para 0,0405 e 0,0205. Em valores absolutos há retorno decrescente (no SOM, a queda é de 0,0637 no primeiro passo e de 0,0267 no segundo), enquanto o tempo cresce (de 0,1 s para 3,8 s no SOM). Como o EQ é uma distância no cubo RGB $[0,1]^3$, um exemplo simples: $EQ = 0{,}02$ equivale a um erro médio de cerca de $0{,}02 \times 255 \approx 5$ níveis em uma escala de 0 a 255.
- **SOM vs. GNG com o mesmo número de neurônios:** a GNG obteve menor EQ em todas as 15 comparações (5 imagens $\times$ 3 tamanhos). Na média, o EQ da GNG é entre 18% e 22% menor (0,0912 vs. 0,1153; 0,0405 vs. 0,0516; 0,0205 vs. 0,0249). Provavelmente porque o SOM precisa manter o grid fixo e ordenado, o que pode deixar neurônios em regiões com poucos pixels, enquanto a GNG insere neurônios onde o erro acumulado é maior e não depende de um grid. Lembrando que $4 \times 4 = 16$, $8 \times 8 = 64$ e $16 \times 16 = 256$.
- **Preservação Topológica:** o ET médio do SOM cresce com o grid (0,0025 $\to$ 0,0077 $\to$ 0,0242, cerca de 10 vezes), enquanto o da GNG permanece baixo e estável (0,0031 $\to$ 0,0073 $\to$ 0,0084).

Com 256 neurônios, o ET do SOM é aproximadamente 2,9 vezes o da GNG. Com 16 neurônios o SOM é ligeiramente melhor (0,0025 vs. 0,0031) e com 64 há praticamente empate (0,0077 vs. 0,0073). Uma explicação plausível é que o SOM projeta o espaço de cores 3D em um grid 2D: quanto mais neurônios, mais o mapa precisa "dobrar" o espaço, e cores próximas podem cair em regiões não adjacentes do grid. Na GNG, a aresta é criada diretamente entre a primeira e a segunda BMU, de modo que as conexões acompanham os dados. Ainda assim, todos os ET ficaram abaixo de 3% (máximo de 0,0303, SOM 16×16 na imagem 1).

- **Ação dos Hiperparâmetros:** a rodada final usa uma única configuração por arquitetura (semente 42), sem varredura sistemática. O raio inicial do SOM foi escalado com o grid (2, 4 e 8, sempre até 0,5) e as iterações com o número de neurônios (500 por neurônio), para que as redes de tamanhos diferentes recebam tratamento comparável. Na GNG, $\epsilon_b = 0{,}2$ é muito maior que $\epsilon_n = 0{,}006$: o vencedor se move bastante e os vizinhos apenas se ajustam, o que ajuda a manter as posições estáveis depois que a rede termina de crescer.

- **Limitações:** foi usada uma única semente, então a variabilidade entre execuções não foi medida; o EQ e o ET são calculados sobre os mesmos pixels usados no treino (sem conjunto de teste separado); as imagens são pequenas (100×100) e em número reduzido (5); e o ET depende da definição de vizinhança de cada modelo (grid no SOM, arestas na GNG), o que torna a comparação direta aproximada. Em compensação, o custo computacional é baixo: as 30 redes foram treinadas em 64 s no total.